



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# Optimización

## Técnicas para NLPs

**Docente: Cristian Guarnizo Lemus**

Somos Innovación Tecnológica con *Sentido Humano*



Alcaldía de Medellín



# Contenido

1. Programas cuadráticos (QPs).
2. Técnicas para NLPs : Eliminación de variables.
3. Métodos de Penalización y de Barrera.

# Programa Cuadrático - QP

La forma general de un programa cuadrático (QP) es:

$$\min_x \frac{1}{2} \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{d}^T \mathbf{x}$$

$$\text{s.t. } \mathbf{a}_i^T \mathbf{x} - b_i = 0, i \in E$$

$$\mathbf{a}_i^T \mathbf{x} - b_i \leq 0, i \in I$$

$\mathbf{a}_i$  es la fila  $i$ -ésima de  $\mathbf{A}$

- $\mathbf{G}$  es una matriz  $(n \times n)$  simétrica.
- Si  $\mathbf{G}$  es semidefinida positiva, entonces QP es convexo. Los QPs son típicamente no convexos, si  $\mathbf{G}$  es indefinida.
- Los problemas cuadráticos con restricciones cuadráticas (QCQP) tienen términos cuadráticos en la función objetivo y las restricciones, y son mucho mas difíciles de solucionar.

# Condiciones KKT de optimalidad para QPs

NLP, programa no-lineal

$$\begin{aligned} \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s.t. } c_i(\mathbf{x}) = 0, i \in E \\ c_i(\mathbf{x}) \leq 0, i \in I \end{aligned}$$

Función Lagrangiana

$$L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \sum_{i \in E \cup I} \lambda_i c_i(\mathbf{x})$$

Condiciones KKT

$$\begin{aligned} \nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*) &= \mathbf{0} \\ c_i(\mathbf{x}^*) &= 0, \forall i \in E \\ c_i(\mathbf{x}^*) &\leq 0, \forall i \in I \\ \lambda_i^* &\geq 0, \forall i \in I \\ \lambda_i^* c_i(\mathbf{x}^*) &= 0, \forall i \in I \end{aligned}$$



QP, programa cuadrático

$$\begin{aligned} \min_{\mathbf{x}} \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{d}^T \mathbf{x} \\ \text{s.t. } \mathbf{a}_i^T \mathbf{x} - b_i = 0, i \in E \\ \mathbf{a}_i^T \mathbf{x} - b_i \leq 0, i \in \{1, \dots, n\} \end{aligned}$$

$$L(\mathbf{x}, \boldsymbol{\lambda}) = \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{d}^T \mathbf{x} + \sum_{i \in E \cup I} \lambda_i (\mathbf{a}_i^T \mathbf{x} - b_i)$$

$$\begin{aligned} \mathbf{G} \mathbf{x}^* + \mathbf{d} + \mathbf{A}^T \boldsymbol{\lambda}^* &= \mathbf{0} \\ \mathbf{a}_i^T \mathbf{x}^* - b_i &= 0, i \in E \\ \mathbf{a}_i^T \mathbf{x}^* - b_i &\leq 0, i \in I \\ \lambda_i^* &\geq 0, \forall i \in I \\ \lambda_i^* (\mathbf{a}_i^T \mathbf{x}^* - b_i) &= 0, \forall i \in I \end{aligned}$$

Ecuaciones No-lineales!  
Bilineales como en los LPs

# Solución de QPs (convexos)

- QPs convexos son muy similares a LPs.
  - Las condiciones KKT son necesarias y suficientes para un optimo global.
  - Estacionariedad lineal, factibilidad primaria lineal, holgura complementaria no-lineal, y limites lineales sobre las variables.
- QPs no convexos son difíciles de solucionar
  - Las condiciones KKT son solamente necesarias, no son suficientes para optimalidad.
  - Algoritmos para la optimización global de NLPs no convexos se puede aplicar.
  - Algoritmos especiales existen pero para entenderlos se requiere su algebra lineal cuidadosamente.



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# Chequeo

Cual es la forma estándar de un QP? Cuando el QP es convexo?



# Contenido

1. Programas cuadráticos (QPs).
2. Técnicas para NLPs : Eliminación de variables.
3. Métodos de Penalización y de Barrera.



# Problema de optimización no-lineal (NLP)

Formulación general:

$$\min_{x \in D} f(x)$$

$$\text{s.t. } c_i(x) = 0, i \in E$$

$$c_i(x) \leq 0, i \in I$$

$x = [x_1, x_2, \dots, x_n]^T \in D$  un vector (punto  $n$ -dimensional)

$D$  conjunto anfiterión

$f: D \rightarrow R$  función objetivo

$c_i: D \rightarrow R$  funciones de restricción  $\forall i \in E \cup I$

$E$  el conjunto índice de las restricciones de igualdad

$I$  el conjunto índice de las restricciones de desigualdad

- Tres estrategias de solución:
  - **Eliminación de variables** (convertir a un problema sin restricciones).
  - Aproximación como una serie de problemas sin restricción.
  - Aproximación como una serie de problemas mas simples con restricciones.



# Eliminación de variables: Idea

$$\min_{x \in D} f(x)$$

$$\text{s.t. } c_i(x) = 0, i \in E$$

- $n$  variables y  $m$  igualdades  $\rightarrow n - m$  grados de libertad para la optimización.
- Idea: **simplificar** el problema **eliminando**  $m$  variables usando las igualdades.

$$x = \begin{bmatrix} y \\ z \end{bmatrix} \begin{array}{l} \leftarrow \text{dimension } n - m \\ \leftarrow \text{dimension } m \end{array} \quad \longrightarrow \quad \min_y \tilde{f}(y)$$

## Observaciones:

- Se necesita poder solucionar las funciones  $c_i(x)$  para  $z(y)$ .
  - La eliminación puede ser simbólica o numérica.
  - Posible para igualdades lineales y no-lineales.
  - Algunas veces “formulación de espacio reducido”.

# Eliminación de variables: Ejemplo

$$\begin{aligned} \min_{x \in \mathbb{R}^2} f(x) &= 4x_1 + 5x_2^2 \\ \text{s.t. } \sqrt{x_1} + x_2 &= 3 \end{aligned}$$

Solucionar para  $x_1$  e insertar en la función objetivo:

$$\begin{aligned} x_1 &= (3 - x_2)^2 \\ \min_{x_2} f(x_2) &= 9x_2^2 - 24x_2 + 36 \end{aligned}$$

Solucionar para el problema sin restricciones:

$$\left. \frac{d\tilde{f}}{dx_2} \right|_{x_2} = 18x_2 - 24 \quad \Rightarrow \quad x_2^* = 4/3$$

$$\left. \frac{d^2\tilde{f}}{dx_2^2} \right|_{x_2} = 18 > 0$$


Problema estrictamente convexo: el punto estacionario es un mínimo global. El problema original parecía no-convexo.

# Como seleccionar un solver

- **Muchas opciones:**
  - Directo vs Indirecto.
  - Punto interior vs conjunto activo.
  - Aproximación de orden, por ejemplo: primer orden (steepest descent), segundo orden (método de Newton).
  - Secuencia de problemas con restricciones o sin restricciones.
  - Espacio completo o reducido?
  - Iteraciones factibles o infactibles?
- **Nos interesa:** robustez, encontrar un buen mínimo local, bajo tiempo de CPU, memoria aceptable.
- Muchos solvers existentes, la mayoría disponible para múltiples plataformas.
- **Recordar la complejidad aritmética:** tiempo CPU = # iteraciones \* tiempo CPU/iteración
  - Cada factor depende del solver y la estructura del problema!

# Comparación cuantitativa de Solvers

- Comparar solvers es una tarea difícil:
  - Métrica de comparación?
  - valores para las tolerancias y opciones de sintonización?.
  - como manejar las instancias fallidas.
- Métricas utilizadas:
  - Tiempo de CPU.
  - Tiempo de CPU escalado al mejor solver.
  - # evaluaciones de la funciones.
  - # iteraciones.
- Perfiles de desempeño de Dolan-Moré: orden de los solver por # de problemas solucionados como función de la métrica seleccionada:
  - No se puede distinguir de forma segura entre los mejores solvers.
  - La métrica seleccionada cambia con el orden.



S = tiempo de CPU en min. Mittelmann NLP benchmarl.

Prof. Mittelmann (<http://plato.la.asu.edu/bench.html>)



# Chequeo

Que estrategias existen para la solución general de NLPs?

La eliminación de variables siempre es segura de aplicar? Cuales son las desventajas?

Cuales son las graficas de desempeño y como se pueden usar?



# Contenido

1. Programas cuadráticos (QPs).
2. Técnicas para NLPs : Eliminación de variables.
3. **Métodos de Penalización y de Barrera.**

# Métodos de Penalización y Barrera

- Idea: reemplazar el problema de restricciones por una secuencia de problemas de optimización sin restricciones. Como remover las restricciones?
- **Método de penalización cuadrático (QPM)**: reemplazar las restricciones adicionando una penalización cuadrático en la función objetivo.
  - Aproximación desde los puntos infactibles.
- **Método del Langrangiano Aumentado (ALM)**: Mejora de QPM que evita los mal-condicionamientos por medio de la estimación de los parámetros de Lagrange.
- **Método de Log-Barrier (LBM)**: usar la barrera del logaritmo para forzar una estricta satisfacción de las desigualdades.
  - Aproximación desde los puntos factibles.



# QPM – Restricciones de Igualdad

Reemplazar cada restricción por un **termino de penalización cuadrático** en la función objetivo

$$\min_{x \in D} f(x)$$

$$\text{s.t. } c_i(x) = 0, i \in E$$

**Función de penalización cuadrática:**  $Q(x; \mu) = f(x) + \frac{1}{2\mu} \sum_{i \in E} [c_i(x)]^2$


- Con parámetro de penalización  $\mu > 0$ .
- Construir una secuencia  $\{\mu^{(k)}\}$  con  $\mu^{(k)} \rightarrow 0$  y minimizar  $Q(x; \mu^{(k)})$ .
  - $x^{(k)}$  son soluciones aproximadas **infactibles** del problema original.
  - La solución optima de un paso es la adivinación inicial para la siguiente.
- Para  $\mu \rightarrow 0$  la violación de la restricción es **incrementalmente** penalizada.
  - La aproximación se mejor de forma progresiva.
  - $x^{(k)}$  converge a la solución, sí  $Q(x; \mu^{(k)})$  son minimizados globalmente.

# QPM – Restricciones de Igualdad

$$\min_{x \in \mathbb{R}^2} x_1 + x_2$$


$$\text{s.t. } x_1^2 + x_2^2 - 2 = 0$$

$\mu = 50$



$$Q(x; 50) = x_1 + x_2 + \frac{1}{100}(x_1^2 + x_2^2 - 2)^2$$

$\mu = 5$



$$Q(x; 5) = x_1 + x_2 + \frac{1}{10}(x_1^2 + x_2^2 - 2)^2$$

# QPM – Incluir restricciones de desigualdad

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & c_i(\mathbf{x}) = 0, i \in E \\ & c_i(\mathbf{x}) \leq 0, i \in I \end{aligned}$$

- El signo de la desigualdades **importa**:

$$Q(\mathbf{x}; \mu) = f(\mathbf{x}) + \frac{1}{2\mu} \sum_{i \in E} [c_i(\mathbf{x})]^2 + \frac{1}{2\mu} \sum_{i \in I} [\max(0, c_i(\mathbf{x}))]^2$$

## Algoritmo QPM:

- Dado  $\mu^{(1)} > 0$ ,  $\tau^{(1)} > 0$  y un punto inicial  $\mathbf{x}^{(0)}$
- Para**  $k = 1, 2, \dots$ 
  - Usar  $\mathbf{x}^{(k-1)}$  como punto inicial (aleatorio). Solucionar  $\mathbf{x}^{(k)} \in Q(\mathbf{x}; \mu^{(k)})$  aproximadamente:  
 $\|\nabla_{\mathbf{x}} Q(\mathbf{x}^{(k)}; \mu^{(k)})\| < \tau^{(k)} \mu^{(k)}$ .
  - SI** el gradiente y la violación de la restricción son suficientemente pequeñas,  
**PARAR**:  $\mathbf{x}^* = \mathbf{x}^{(k)}$ .
  - DE LO CONTRARIO** seleccionar  $\mu^{(k+1)} \in (0, \mu^{(k)})$ ,  $\tau^{(k+1)}$  (s.t.  $\lim_{k \rightarrow \infty} \tau^{(k)} = 0$ )

# Observaciones de QPM

- El parámetro  $\mu^{(k)}$  puede ser seleccionado adaptativamente.
  - Si  $\min_x Q(x; \mu^{(k)})$  fue difícil, reducir  $\mu$  de manera modesta:  $\mu^{(k+1)} = 0.7\mu^{(k)}$ .
  - Si  $\min_x Q(x; \mu^{(k)})$  fue fácil, reducir  $\mu$  mas rápidamente:  $\mu^{(k+1)} = 0.1\mu^{(k)}$ .
- Para restricciones de igualdad, la función de penalización es suave
  - Continua para la primera derivada, pero discontinua para la segunda derivada.
- Como  $\mu^{(k)} \rightarrow 0$ , solucionar  $\min_x Q(x; \mu^{(k)})$  es cada vez mas difícil.
  - La Hessiana se vuelve mas y mas mal-condicionada.
  - El método del Lagrangiano Aumentado alivia este problema.

# ALM: Restricciones de Igualdad

$$\begin{aligned} \min_{\mathbf{x} \in D} f(\mathbf{x}) \\ \text{s.t. } c_i(\mathbf{x}) = 0, i \in E \end{aligned}$$

Lagrangiano:  $L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \sum_{i \in E} \lambda_i c_i(\mathbf{x})$

Lagrangiano Aumentado:  $L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \sum_{i \in E} \lambda_i c_i(\mathbf{x}) + \frac{1}{2\mu} \sum_{i \in E} [c_i(\mathbf{x})]^2$

- Ventaja de ALM con respecto a QPM: pequeña violación de la restricción para un  $\mu$  relativamente grande.
  - Evita problemas numéricos de mal-condicionamiento.
- Como seleccionar de manera iterativa los parámetros  $\mu$  y  $\lambda$ ?



# ALM: Restricciones de Igualdad

- Gradiente de la función Lagrangiana Aumentada:

$$\nabla_x L_A(\mathbf{x}, \boldsymbol{\lambda}, \mu) = \nabla_x f(\mathbf{x}) + \sum_{i \in E} \left( \lambda_i + \frac{c_i(\mathbf{x})}{\mu} \right) \nabla_x c_i(\mathbf{x})$$

- $\operatorname{argmin}_{\mathbf{x}} L_A(\mathbf{x}, \boldsymbol{\lambda}^{(k)}, \mu^{(k)})$  debería ser aproximado  $\min_{\mathbf{x} \in E} f(\mathbf{x})$
- La estacionariedad en  $L(\mathbf{x}, \boldsymbol{\lambda})$  implica  $\lambda_i^* \approx \lambda_i^{(k)} + \frac{c_i(\mathbf{x}^{(k)})}{\mu^{(k)}}$
- Si  $\lambda_i^* \approx \lambda_i^{(k)}$ , la violación de las restricciones es pequeña debido que  $c_i(\mathbf{x}^{(k)}) \approx \mu^{(k)} (\lambda_i^* - \lambda_i^{(k)})$ 
  - Aun para un  $\mu^{(k)}$  grande.
- Como  $\lambda_i^*$  es desconocido, nosotros iterativamente actualizamos:  $\lambda_i^{(k+1)} = \lambda_i^{(k)} + \frac{c_i(\mathbf{x})}{\mu^{(k)}}$
- Algoritmo similar a QPM pero converge para  $\mu$  mas grandes. Se espera menos iteraciones y mejor condicionamiento.

# QPM vs ALM: Ejemplo

$$\min_{x_1, x_2} [1.5 - x_1(1 - x_2)]^2 + [2.25 - x_1(1 - x_2^2)]^2 + [2.625 - x_1(2.625 - x_1(1 - x_2^3))]^2$$


$$\text{s.t. } x_1^2 + x_2^2 - 1 = 0$$

## QPM:

- Converge después de 39 iteraciones.
- $\mu^{(39)} = 10^{-8}$

## ALM:

- Converge después de 28 iteraciones.
- $\mu^{(28)} = 10^{-4}$
- Estimaciones del multiplicador de Lagrange  
 $\lambda = 0 \rightarrow \dots \rightarrow -2.63 \rightarrow -3.33 \rightarrow -3.35$



$$\mathbf{x}^{(0)} = \frac{\sqrt{2}}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\mathbf{x}^* = \begin{bmatrix} 0.997 \\ -0.07744 \end{bmatrix}$$

$$f(\mathbf{x}^*) = 4.42$$





Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# Chequeo

Cual es la idea principal en los métodos de penalización?

Cual es la idea principal en el método de Lagrangiano Aumentado?

# Referencias

- Basado en el curso “Applied Numerical Optimization” por el profesor Alexander Mitsos.
- Nocedal J. Wright S. J. Numerical Optimization, 2nd Edition, Springer, 2006.



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# *¡Gracias!*

Somos Innovación Tecnológica con *Sentido Humano*



Alcaldía de Medellín