



Institución
Universitaria
Reacreditada en Alta Calidad

Optimización

Técnicas para NLPs

Docente: Cristian Guarnizo Lemus

Somos Innovación Tecnológica con *Sentido Humano*



Alcaldía de Medellín



Contenido

1. Métodos de Penalización y de Barrera.
2. Serie de problemas mas simples con Restricciones (LCL, SQP)

Métodos de Penalización y Barrera

- Idea: reemplazar el problema de restricciones por una secuencia de problemas de optimización sin restricciones. Como remover las restricciones?
- **Método de penalización cuadrático (QPM)**: reemplazar las restricciones adicionando una penalización cuadrático en la función objetivo.
 - Aproximación desde los puntos infactibles.
- **Método del Langrangiano Aumentado (ALM)**: Mejora de QPM que evita los mal-condicionamientos por medio de la estimación de los parámetros de Lagrange.
- **Método de Log-Barrier (LBM)**: usar la barrera del logaritmo para forzar una estricta satisfacción de las desigualdades.
 - Aproximación desde los puntos factibles.

Método de Barrera logarítmica (LBM): desigualdades

$$\min_{x \in R^n} f(x)$$

$$\text{s.t. } c_i(x) \leq 0, i \in I$$

- Reemplazar la restricciones por una barrera de logaritmo en la función objetivo:

$$P(x; \mu) = f(x) - \mu \sum_{i \in I} \log[-c_i(x)]$$


con parámetro de barrera $\mu > 0$.

- La barrera impone **iteraciones estrictamente factibles**
 - $P(x; \mu) \rightarrow \infty$ para $0 > c_i(x) \rightarrow 0$. Entonces, para $\mu > 0$ se impone $c(x) < 0$.
- Similar a QPM, solucionar una secuencia de problemas sin restricción
 - Solucionar en una iteración el inicio de la siguiente iteración.
 - Mientras $\mu \rightarrow 0$, las aproximaciones de x se vuelven mejores.

La barrera logarítmica LogBar

$$\begin{aligned} \min_{x \in \mathbb{R}} \quad & x \\ \text{s.t. } \quad & x \geq 0 \\ & x \leq 1 \end{aligned}$$

$$P(x; \mu) = x - \mu (\log[x] + \log[1 - x])$$



Barrera logarítmica (LBM): Igualdades y Desigualdades

Problema NLP general: $\min_{x \in R^n} f(x)$

$$\text{s.t. } c_i(x) = 0, i \in E$$

$$c_i(x) \leq 0, i \in I$$

- Reemplazar las restricciones de **desigualdad** por una **barrera logarítmica**
- Reemplazar las restricciones de **igualdad** por una **penalización cuadrática**

$$B(x; \mu) = f(x) + \frac{1}{2\mu} \sum_{i \in E} [c_i(x)]^2 - \mu \sum_{i \in I} \log[-c_i(x)]$$

- Similar al caso de las desigualdades, solucionamos con una secuencia de problemas sin restricciones.
- Método de punto interior con respecto a: $c_i(x^{(k)}) < 0, i \in I$
- Violación de las restricciones de igualdad: $c_i(x^{(k)}) \neq 0, i \in E$
 - Las igualdades no tienen interior.



Chequeo

Cual es la idea principal en los métodos de barrera?

Cual es la diferencia entre los métodos de penalización cuadrático y el método de barrera?



Contenido

1. Métodos de Penalización y de Barrera.
2. Serie de problemas mas simples con Restricciones (LCL, SQP)

Problema de optimización no-lineal (NLP)

Formulación general:

$$\min_{x \in D} f(x)$$

$$\text{s.t. } c_i(x) = 0, i \in E$$

$$c_i(x) \leq 0, i \in I$$

$x = [x_1, x_2, \dots, x_n]^T \in D$ un vector (punto n -dimensional)

D conjunto anfitrón

$f: D \rightarrow R$ función objetivo

$c_i: D \rightarrow R$ funciones de restricción $\forall i \in E \cup I$

E el conjunto índice de las restricciones de igualdad

I el conjunto índice de las restricciones de desigualdad

- Tres estrategias de solución:
 - Eliminación de variables (convertir a un problema sin restricciones).
 - Aproximación como una serie de problemas sin restricción.
 - **Aproximación como una serie de problemas mas simples con restricciones.**

Método Lagrangiano con restricciones lineales

El método del Lagrangiano con restricciones lineales (LCL) es una modificación del método del Lagrangiano Aumentado.

- En cada paso, **se linealizan** las restricciones.

- Para el problema $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$

$$\text{s.t. } c_i(\mathbf{x}) = 0, \quad i \in E$$

en la iteración k resolver $\min_{\mathbf{x} \in \mathbb{R}^n} F^{(k)}(\mathbf{x})$

$$\text{s.t. } \nabla c_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + c_i(\mathbf{x}^{(k)}) = 0, \quad i \in E$$

- Para $F^{(k)}$, a menudo se selecciona el Lagrangiano Aumentado.

$$F^{(k)}(\mathbf{x}) = f(\mathbf{x}) + \sum_{i \in E} \lambda_i^{(k)} \bar{c}_i^{(k)}(\mathbf{x}) + \frac{1}{2\mu} \sum_{i \in E} [\bar{c}_i^{(k)}(\mathbf{x})]^2$$

$$\bar{c}_i^{(k)}(\mathbf{x}) = c_i(\mathbf{x}) - c_i(\mathbf{x}^{(k)}) - \nabla c_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)})$$

Programación Secuencial Cuadrática (SQP)

- SQP provee la base para algunos buenos códigos de optimización.
- Se considera el siguiente problema de optimización

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$
$$\text{s.t. } c_i(\mathbf{x}) = 0, \quad i \in E$$

- **Idea principal:** solucionar una secuencia $\{k\}$ de QPs, donde se aproxima el NLP en la iteración $\mathbf{x}^{(k)}$ por una QP.
- La forma mas fácil: Aproximación por series de Taylor

$$\min_{\mathbf{p} \in \mathbb{R}^n} \frac{1}{2} \mathbf{p}^T \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p} + (\nabla f(\mathbf{x}^{(k)}))^T \mathbf{p}$$
$$\text{s.t. } \left(\nabla \mathbf{c}(\mathbf{x}^{(k)}) \right)^T \mathbf{p} + \mathbf{c}(\mathbf{x}^{(k)}) = \mathbf{0}$$

- Se puede interpretar como el método de Newton para solucionar las condiciones KKT.


Algoritmo Básico SQP

Puntos importantes **no** discutidos:

- Aproximación de la matriz Hessiana (p.e., actualización BFGS, en métodos quasi Newtons).
- Solución de las ecuaciones Newton-Lagrange en cada paso del QP.
- Criterio de parada.
- Inclusión de desigualdades.

Algoritmo Básico:

- Seleccionar $\mathbf{x}^{(0)}$.
- Para $k = 1, 2, \dots$
 - Calcular $f^{(k)} = f(\mathbf{x}^{(k-1)})$, $\nabla f^{(k)} = \nabla f(\mathbf{x}^{(k-1)})$, $\mathbf{c}^{(k)} = \mathbf{c}(\mathbf{x}^{(k-1)})$, $\mathbf{A}^{(k)} = \nabla \mathbf{c}(\mathbf{x}^{(k-1)})$, actualizar $\mathbf{B}^{(k)}$.
 - Solucionar el QP para \mathbf{p} .
 - $\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + \mathbf{p}$.
 - Si las condiciones de optimalidad se satisfacen, **PARAR**.



Método Quasi-Newton

Definiciones: $f^{(k)} = f(\mathbf{x}^{(k)})$, $\mathbf{g}^{(k)} := \nabla f(\mathbf{x}^{(k)})$ y $\mathbf{H}^{(k)} := \nabla^2 f(\mathbf{x}^{(k)})$

Del método de Newton:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{p}^{(k)}$$

$$[\nabla^2 f(\mathbf{x}^{(k)})]\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)}) \Rightarrow \mathbf{H}^{(k)}\mathbf{p}^{(k)} = -\mathbf{g}^{(k)}$$

Idea:

El sistema lineal $\mathbf{H}^{(k)}\mathbf{p}^{(k)} = -\mathbf{g}^{(k)}$ se puede solucionar aproximadamente por un método iterativo.

Observaciones:

Factorizaciones como LU o Cholesky – costo computacional alto.

Ocurren errores grandes para problemas mal condicionados.

No se requiere la solución exacta.

Método Quasi-Newton (2)

Idea: reducir la complejidad simplificando el cálculo de $H^{(k)}$ (Davidon):

- Reemplazar $H^{(k)}$ por una aproximación $B^{(k)}$.
- En vez de calcular $B^{(k)}$, buscamos una simple actualización usando la información de las últimas iteraciones.

Método:

- Considerar la aproximación cuadrática de f en $x^{(k)}$, $m^{(k)}(p) = f^{(k)} + [g^{(k)}]^T p + \frac{1}{2} p^T B^{(k)} p$.
- Condición de optimalidad de primer orden: $p^{(k)} = -B^{(k)^{-1}} g^{(k)}$
- Por convexidad es necesaria y suficiente para la minimización de $m^{(k)}(p)$.
- Construir la aproximación cuadrática en $x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$

$$m^{(k+1)}(p) = f^{(k+1)} + [g^{(k+1)}]^T p + \frac{1}{2} p^T B^{(k+1)} p$$

- Que condiciones debe satisfacer $B^{(k+1)}$?

Método Quasi-Newton (3)

Condiciones de $B^{(k+1)}$:

1. Gradiente de $m^{(k+1)}$ en $x^{(k+1)}$ debe ser igual al gradiente de f .

$\nabla m^{(k+1)}(p) = g^{(k+1)} + B^{(k+1)}p$	
At $x = x^{(k+1)}$, $p = 0$ Queremos $\nabla m^{(k+1)}(0) = g^{(k+1)}$	At $x = x^{(k)}$, $p = -\alpha_k p^{(k)}$ Queremos $\nabla m^{(k+1)}(-\alpha_k p^{(k)}) = g^{(k)}$
Satisface automáticamente	$\Rightarrow g^{(k+1)} - \alpha_k B^{(k+1)} p^{(k)} = g^{(k)}$ $\Rightarrow B^{(k+1)} \underbrace{\alpha_k p^{(k)}}_{=x^{(k+1)} - x^{(k)}} = g^{(k+1)} - g^{(k)}$ $\Rightarrow B^{(k+1)} s^{(k)} = y^{(k)}, \text{ donde } s^{(k)} = x^{(k+1)} - x^{(k)} \text{ y } y^{(k)} = g^{(k+1)} - g^{(k)}$

2. Debido que $B^{(k+1)}$ es simétrica definida positiva: $s^{(k)T} B^{(k+1)} s^{(k)} > 0, \forall s^{(k)} \neq 0 \Rightarrow s^{(k)T} y^{(k)} > 0$

Método Quasi-Newton (3)

Condiciones de $B^{(k+1)}$:

$B^{(k+1)}s^{(k)} = y^{(k)}$ gives many solutions for $B^{(k+1)}$

- **Unique** solution: $B^{(k+1)}$ should be close to $B^{(k)}$

$$\min_B \|B - B^{(k)}\|_W \quad \leftarrow \text{weighted Frobenius-Norm}$$

$$\text{s.t. } B^T = B$$

$$\|A\|_W = \|W^{1/2}AW^{1/2}\|_F, \text{ for any } W \text{ s.t. } Wy_k = s_k$$

$$Bs^{(k)} = y^{(k)}$$

$$\|\cdot\|_F^2: R^{n \times n} \rightarrow R_{\geq 0}, \|C\|_F^2 = \sum_{i=1}^n \sum_{j=1}^n c_{ij}^2$$

$$\Rightarrow B^{(k+1)} = \left(I - \frac{1}{y^{(k)T}s^{(k)}} y^{(k)} s^{(k)T} \right) B^{(k)} \left(I - \frac{1}{y^{(k)T}s^{(k)}} s^{(k)} y^{(k)T} \right) + \frac{1}{y^{(k)T}s^{(k)}} y^{(k)} y^{(k)T} \rightarrow \text{DFP formula}$$

$$\Rightarrow B^{(k+1)-1} = \left(I - \frac{1}{y^{(k)T}s^{(k)}} s^{(k)} y^{(k)T} \right) B^{(k)-1} \left(I - \frac{1}{y^{(k)T}s^{(k)}} y^{(k)} s^{(k)T} \right) + \frac{1}{y^{(k)T}s^{(k)}} s^{(k)} s^{(k)T} \rightarrow \text{BFGS formula}$$



Institución
Universitaria
Reacreditada en Alta Calidad

¡Gracias!

Somos Innovación Tecnológica con *Sentido Humano*



Alcaldía de Medellín